

**Московский государственный технический
университет им. Н. Э. Баумана**

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №1

«Технологии разведочного анализа и обработки данных.»

Вариант № 17

Выполнил:

Хабленко И. Д.
группа ИУ5-63Б

Проверил:

Гапанюк Ю.Е.

Дата: 15.04.25

Дата:

Подпись:

Подпись:

Москва, 2025 г.

Задание:

Номер варианта: 17

Номер задачи: 3

Номер набора данных, указанного в задаче: 1 (https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_iris.html#sklearn.datasets.load_iris)

Для студентов групп ИУ5-63Б, ИУ5Ц-83Б - для произвольной колонки данных построить график «Ящик с усами (boxplot)».

Задача №3.

Для заданного набора данных произведите масштабирование данных (для одного признака) и преобразование категориальных признаков в количественные двумя способами (label encoding, one hot encoding) для одного признака. Какие методы Вы использовали для решения задачи и почему?

Ход выполнения:

РК1. Вариант 17. Задача №3.



Для заданного набора данных произведите масштабирование данных (для одного признака) и преобразование категориальных признаков в количественные двумя способами (label encoding, one hot encoding) для одного признака. Какие методы Вы использовали для решения задачи и почему?

```
from sklearn.datasets import load_iris
import pandas as pd
from sklearn.preprocessing import StandardScaler, LabelEncoder, OneHotEncoder
import matplotlib.pyplot as plt
import seaborn as sns
```

✓ 0.0s

Python

Загрузка датасета 1 (https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_iris.html#sklearn.datasets.load_iris)

```
iris = load_iris()
df = pd.DataFrame(data=iris.data, columns=iris.feature_names)
df['species'] = iris.target_names[iris.target]
```

```
print("Первые 5 строк датасета:")
print(df.head())
```

✓ 0.0s

Python

```
Первые 5 строк датасета:
  sepal length (cm)  sepal width (cm)  petal length (cm)  petal width (cm) \
0                5.1                3.5                1.4                0.2
1                4.9                3.0                1.4                0.2
2                4.7                3.2                1.3                0.2
3                4.6                3.1                1.5                0.2
4                5.0                3.6                1.4                0.2

species
0  setosa
```

Масштабирование sepal length (cm)

[+ Code](#) [+ Markdown](#)

```
scaler = StandardScaler()
df['sepal_length_scaled'] = scaler.fit_transform(df[['sepal length (cm)']])

print("\nДо и после масштабирования 'sepal length (cm)':")
print(df[['sepal length (cm)', 'sepal_length_scaled']].head())
```

✓ 0.0s

Python

```
До и после масштабирования 'sepal length (cm)':
sepal length (cm)  sepal_length_scaled
0                5.1          -0.900681
1                4.9          -1.143017
2                4.7          -1.385353
3                4.6          -1.506521
4                5.0          -1.021849
```

Label Encoding (Кодирование метками)

- Каждой категории присваивается уникальное целое число. (Setosa – 0, Versicolor – 1, Virginica – 2).
- Подходит для порядковых данных (где есть иерархия, например, «низкий» < «средний» < «высокий»).

Преобразование категориальных признаков в количественные способом label encoding для species

[+ Code](#) [+ Markdown](#)

```
encoder = LabelEncoder()
df['species_label'] = encoder.fit_transform(df['species'])

print("\nLabel Encoding для 'species':")
print(df[['species', 'species_label']].head())

print("\nВсе уникальные виды и их метки:")
unique_species = df[['species', 'species_label']].drop_duplicates()
print(unique_species.sort_values('species_label'))
```

✓ 0.0s

Python

```
Label Encoding для 'species':
species  species_label
0  setosa              0
1  setosa              0
2  setosa              0
3  setosa              0
4  setosa              0
```

```
Все уникальные виды и их метки:
species  species_label
0  setosa              0
50  versicolor         1
100  virginica          2
```

One-Hot Encoding (Бинарное кодирование):

- Каждая категория превращается в отдельный бинарный признак (0 или 1).
- Подходит для номинальных данных (где нет порядка).

Преобразование категориальных признаков в количественные способом one hot encoding для species

[+ Code](#) [+ Markdown](#)

```
encoder = OneHotEncoder(sparse_output=False, drop='first')
encoded_species = encoder.fit_transform(df[['species']])

encoded_df = pd.DataFrame(encoded_species,
                           columns=encoder.get_feature_names_out(['species']))

df = pd.concat([df, encoded_df], axis=1)

print("\nOne-Hot Encoding для 'species':")
print(df[['species', 'species_versicolor', 'species_virginica']].head())

print("\nВсе уникальные виды и их метки:")
unique_species_ = df[['species', 'species_versicolor', 'species_virginica']].drop_duplicates()
print(unique_species_)
```

✓ 0.0s

Python

One-Hot Encoding для 'species':

	species	species_versicolor	species_virginica
0	setosa	0.0	0.0
1	setosa	0.0	0.0
2	setosa	0.0	0.0
3	setosa	0.0	0.0
4	setosa	0.0	0.0

Все уникальные виды и их метки:

	species	species_versicolor	species_virginica
0	setosa	0.0	0.0
50	versicolor	1.0	0.0
100	virginica	0.0	1.0

```
print("\nИтоговый датасет:")
print(df.head())

print("\nВсе уникальные виды и их метки:")
unique_species_ = df[['species', 'species_label', 'species_versicolor', 'species_virginica']].drop_duplicates()
print(unique_species_)
```

✓ 0.0s

Python

Итоговый датасет:

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	\
0	5.1	3.5	1.4	0.2	
1	4.9	3.0	1.4	0.2	
2	4.7	3.2	1.3	0.2	
3	4.6	3.1	1.5	0.2	
4	5.0	3.6	1.4	0.2	

	species	sepal length_scaled	species_label	species_versicolor	\
0	setosa	-0.900681	0	0.0	
1	setosa	-1.143017	0	0.0	
2	setosa	-1.385353	0	0.0	
3	setosa	-1.506521	0	0.0	
4	setosa	-1.021849	0	0.0	

	species_virginica
0	0.0
1	0.0
2	0.0
3	0.0
4	0.0


Все уникальные виды и их метки:

	species	species_label	species_versicolor	species_virginica
0	setosa	0	0.0	0.0
50	versicolor	1	1.0	0.0
100	virginica	2	0.0	1.0

Для произвольной колонки данных построить график "Ящик с усами (boxplot)"

```
column_name = 'sepal length (cm)'\n\nplt.figure(figsize=(8, 6))\nboxplot = plt.boxplot(\n    df[column_name],\n    patch_artist=True,\n    boxprops=dict(facecolor='pink', color='violet'),\n    whiskerprops=dict(color='violet'),\n    capprops=dict(color='violet'),\n    medianprops=dict(color='purple')\n)\nplt.title(f'Boxplot для {column_name}')\nplt.ylabel('Значения')\nplt.show()\n\nplt.figure(figsize=(8, 6))\nsns.boxplot(\n    data=df[column_name],\n    color='pink',\n    width=0.3,\n    orient='h'\n)\nplt.title(f'Boxplot для {column_name}')\nplt.xlabel(column_name)\nplt.show()
```

✓ 0.2s Python



Boxplot для sepal length (cm)

